



GRENOBLE INP - ENSIMAG / UGA

RAPPORT DE STAGE ASSISTANT INGÉNIEUR

Sélection de Variables Informées par la Taxonomie pour la Localisation Spatiale du Microbiote

Évaluation Comparative : HFE vs SFE

Auteur :

Ahmed BENNASSER

Organismes d'Accueil :

LIG (Équipe APTIKAL)

TIMC (Équipe TrEE-compbio)

Encadrants de Stage :

Zakaria TOUGUI (LIG)

Antoine FRENOY (LIG)

Nelle VAROQUAUX (TIMC)

Tuteur de Stage :

Martin Heusse

Dates du stage : 01/06/2026 – 31/07/2026

Durée du stage : 2 Mois

Table des matières

1	Introduction	1
2	État de l’art et problématique	1
2.1	Données microbiomiques	1
2.2	Préparation des données microbiomiques	2
2.3	Construction et préparation des jeux de données	2
2.4	Défis de l’apprentissage automatique sur les données microbiomiques	3
2.5	Limites des approches classiques	3
2.6	Méthodes informées par la taxonomie	4
2.7	Problématique	4
2.8	Objectifs du stage	4
3	Méthodes Proposées	5
3.1	HFE (Hierarchical Feature Engineering)	5
3.2	Limites de HFE	6
3.3	SFE (Statistical Feature Engineering)	6
3.4	Implémentation (Pipeline scikit-learn)	7
3.5	Protocole d’Évaluation : Validation Croisée Imbriquée	7
4	Évaluation Expérimentale	8
4.1	Test sanitaire sur les jeux de données CRC	8
4.2	Performance : Validation intra-étude	9
4.3	Validation inter-études (LOSO)	10
4.4	Analyse du comportement de HFE SFE	11
4.4.1	Évaluation de la Stabilité de Sélection et de la Robustesse au Bruit	11
4.4.2	Impact de la Haute Dimensionnalité (p/N)	13
4.4.3	Test de contrôle par sélection aléatoire des variables	14
5	Discussion	15
5.1	Comparaison HFE et SFE	15
5.2	Impact de la structure taxonomique	16
5.3	Limites expérimentales	16
5.4	Perspectives	16
6	Conclusion	17
7	Bilan personnel	17
8	ANNEXE	21

Table des figures

1	Représentation schématique du fonctionnement par étapes de HFE : a. Arbre taxonomique initial ; b. Filtrage par corrélation parent-enfant ; c. Sélection par Gain d'Information ; d. Espace final de variables conservées.	5
2	Architecture globale de la méthode SFE (Statistical Feature Engineering). a. Génération de l'espace augmenté par agrégation taxonomique ; b. Évaluation de la séparation inter-classes par le test de Kruskal-Wallis ; c. Contrôle du taux de faux positives par correction Benjamini-Hochberg ; d. Élimination des redondances par filtrage de corrélation de Spearman.	7
3	Schéma du protocole de Validation Croisée Imbriquée (<i>Nested Cross-Validation</i>). a. La boucle externe isole le jeu de test pour mesurer la généralisation. b. Pour chaque pli externe, le jeu d'entraînement est transmis à la boucle interne afin d'optimiser les hyperparamètres (seuils de corrélation, α FDR, paramètres du classifieur) sur des sous-ensembles de validation.	8
4	Résultats du test sanitaire sur les jeux CRC : (a) Performances de classification sur la cohorte combinée CRC1+CRC2. (b) Performances AUC_ROC obtenues séparément sur les deux études.	9
5	Évaluation de la robustesse au bruit log-normal (σ) entre HFE et SFE. Évolution de la stabilité de sélection (indice de Jaccard, a , d), de la performance prédictive (F_1 -score, b , e) et du nombre de variables sélectionnées (c , f) pour les jeux de données ERP012803 (ligne du haut) et SRP002395 (ligne du bas). Les barres d'erreur indiquent l'écart-type ($\pm$ std).	12
6	Évaluation de l'hypothèse de forte dimensionnalité (p/N). Évolution du F_1 -score en fonction du nombre d'échantillons (N , axe inférieur) et du ratio p/N (axe supérieur) en échelle log, pour les méthodes HFE, SFE et la baseline sans sélection.	14
7	Test de contrôle par sélection aléatoire des variables	15

Liste des tableaux

1	Performances d'intra-étude en validation croisée (Test $F_1 \pm$std) sur 5 plis.	10
2	Performances en inter-études (LOSO). F_1 -score obtenu en test sur l'étude cible isolée.	11
3	Répartition du nombre d'échantillons par étude et par classe biologique pour le jeu de données MicrobeAtlas.	21
4	Distribution du nombre d'échantillons par étude pour 8 études représentatives du dataset Earth Microbiome Project.	21

1 Introduction

Ce stage d'assistant ingénieur a été réalisé au sein du Laboratoire d'Informatique de Grenoble (LIG), dans l'équipe APTIKAL, en collaboration avec l'équipe TrEE-compbio du laboratoire TIMC. Il s'inscrit dans le domaine de la bioinformatique, à l'intersection entre l'analyse de données biologiques et les méthodes d'apprentissage automatique.

Les avancées récentes des technologies de séquençage à haut débit ont profondément transformé l'étude des communautés microbiennes. Ces technologies permettent aujourd'hui de caractériser la composition des microbiotes présents dans différents environnements, allant des écosystèmes naturels aux organismes hôtes. L'accumulation de grandes bases de données microbiologiques, telles que l'**Earth Microbiome Project** (EMP) [Thompson et al. \(2017\)](#) ou **MicrobeAtlas** [Rodrigues et al. \(2026\)](#), offre de nouvelles opportunités pour comprendre l'organisation des communautés microbiennes et identifier les facteurs biologiques associés à leur composition.

Le microbiome constitue ainsi un domaine d'intérêt majeur en biologie moderne. Les microorganismes qui composent ces communautés jouent un rôle essentiel dans de nombreux processus biologiques, notamment dans les interactions entre l'hôte et son environnement, le fonctionnement des écosystèmes et l'étude de certaines pathologies. L'exploitation de ces données nécessite cependant le développement de méthodes informatiques capables d'extraire des informations pertinentes à partir de profils microbiens complexes.

Dans ce contexte, l'objectif de ce stage est d'étudier l'apport des méthodes d'apprentissage automatique pour la classification de profils microbiens et plus particulièrement l'utilisation de méthodes de sélection de variables intégrant l'information taxonomique. **Le travail porte sur l'analyse, la réimplémentation et l'évaluation critique de l'approche "Hierarchical Feature Engineering" (HFE) [Oudah and Henschel \(2018\)](#), proposée pour exploiter la structure hiérarchique des données microbiologiques. Une nouvelle approche, appelée **Statistical Feature Engineering** (SFE), a été *proposée, implémentée et étudiée* afin de comparer différentes stratégies de sélection de variables adaptées aux données microbiomiques.**

Ce rapport présente d'abord le contexte scientifique et les caractéristiques des données étudiées, puis décrit les méthodes développées ainsi que le protocole expérimental utilisé pour leur évaluation. Enfin, les résultats obtenus sont analysés afin de discuter les avantages et les limites des différentes approches.

2 État de l'art et problématique

2.1 Données microbiomiques

Le microbiome correspond à l'ensemble des microorganismes présents dans un environnement donné [Berg et al. \(2020\)](#).

Les données utilisées dans ce travail proviennent de bases publiques telles que l'Earth Microbiome Project (EMP) [Thompson et al. \(2017\)](#) et MicrobeAtlas [Rodrigues et al. \(2026\)](#), contenant des profils microbiens associés à des métadonnées biologiques et environnementales.

L'objectif est de transformer ces profils microbiens en représentations exploitables par des méthodes d'apprentissage automatique afin de prédire une information biologique intéressante [Rojas-Velazquez et al. \(2024\)](#).

2.2 Préparation des données microbiomiques

L'obtention des données microbiomiques repose sur une chaîne expérimentale et bioinformatique permettant de convertir un échantillon biologique en une matrice exploitable par des modèles prédictifs.

La première étape consiste en un **échantillonnage biologique** suivi d'une **extraction de l'ADN** total présent dans la communauté microbienne. Une région du **gène 16S rRNA** est ensuite **séquencée** afin d'identifier les microorganismes présents dans chaque échantillon [Hillman et al. \(2017\)](#).

Les lectures obtenues sont traitées par des **pipelines bioinformatiques tels que DADA2 ou QIIME2**. Ces étapes comprennent le contrôle qualité, la suppression des séquences bruitées, l'identification des variants de séquences (**ASV**) ou **OTU**, ainsi que leur assignation taxonomique [Rodrigues et al. \(2026\)](#), [Thompson et al. \(2017\)](#).

À l'issue de ce traitement, les données sont représentées sous deux formes principales :

- Une **matrice d'abondance** $X \in \mathbb{R}^{n \times p}$, au format (BIOM) [McDonald et al. \(2012\)](#), où chaque ligne correspond à un échantillon et chaque colonne à un taxon (Microbe).
- Une **table taxonomique**, décrivant la classification hiérarchique des taxons selon différents niveaux : **domaine, phylum, classe, ordre, famille, genre et espèce**. [Hillman et al. \(2017\)](#)

Ces deux structures constituent les entrées principales des méthodes d'apprentissage automatique étudiées.

2.3 Construction et préparation des jeux de données

Avant toute étape d'apprentissage, les jeux de données issus de l'Earth Microbiome Project (EMP) [Thompson et al. \(2017\)](#) et de MicrobeAtlas [Rodrigues et al. \(2026\)](#) ont été construits selon un pipeline commun. Cette étape avait pour objectif d'obtenir des ensembles de données représentatifs, de réduire les sources de bruit et de garantir la qualité des évaluations expérimentales.

La préparation des deux jeux de données s'est déroulée selon les étapes suivantes :

1. Extraction des données.

Pour chaque base de données, trois fichiers complémentaires ont été récupérés : (i) la matrice d'abondance microbiologique au format BIOM, (ii) la table taxonomique décrivant la classification hiérarchique des taxons, et (iii) les métadonnées contenant les labels de classification ainsi que les identifiants des études.

2. Intégration des informations.

Les informations taxonomiques ont été associées à la matrice d'abondance, tandis que les métadonnées ont permis d'associer chaque échantillon à sa classe biologique et à son étude d'origine. Cette étape aboutit à un jeu de données cohérent reliant abondances, taxonomie et annotations.

3. Filtrage des taxons.

Les taxons faiblement représentés dans les échantillons ont été supprimés selon un critère de prévalence afin de limiter le bruit et de réduire la dimension des données.

4. Sélection des études et des classes.

Les études et les classes biologiques ont ensuite été sélectionnées selon leur représentativité afin de conserver uniquement les ensembles disposant d'un nombre suffisant d'échantillons pour les expérimentations.

5. Agrégation taxonomique.

Les profils microbiens, initialement annotés au niveau de l'espèce, ont été agrégés au niveau du genre afin de réduire la variabilité associée aux taxons très spécifiques tout en conservant une résolution taxonomique pertinente.

6. Normalisation des abondances.

Enfin, les comptages ont été transformés en **abondances relatives** afin de limiter l'effet de la profondeur de séquençage [Oudah and Henschel \(2018\)](#) :

$$x'_{ij} = \frac{x_{ij}}{\sum_{k=1}^p x_{ik}}$$

- La répartition exacte du jeu de données nettoyé pour **MicrobeAtlas** est détaillée dans la matrice complète du Tableau 3 (en ANNEXE).
- Concernant le jeu de données **Earth Microbiome Project** (EMP), en raison du grand nombre d'études (34 études au total), un sous-ensemble représentatif de 8 études clés est présenté dans le Tableau 4 (en ANNEXE).

Le problème étudié peut alors être formulé comme une tâche de classification supervisée :

$$f(X) \rightarrow y$$

où X représente le profil microbiologique d'un échantillon et y la classe associée.

2.4 Défis de l'apprentissage automatique sur les données microbiomiques

Les données microbiomiques présentent plusieurs caractéristiques qui rendent leur analyse difficile :

- **Haute dimensionnalité** : le nombre de variables taxonomiques peut être supérieur au nombre d'échantillons disponibles, augmentant le risque de surapprentissage [Rojas-Velazquez et al. \(2024\)](#).
- **Sparsité** : une grande partie des taxons présente des abondances nulles dans de nombreux échantillons, ce qui complique l'identification des variables pertinentes [Rojas-Velazquez et al. \(2024\)](#).
- **Nature compositionnelle** : les abondances relatives sont contraintes par la profondeur totale de séquençage [Silverman et al. \(2017\)](#).
- **Effet batch** : les différences entre études peuvent être liées aux protocoles expérimentaux plutôt qu'à des différences biologiques réelles, limitant la généralisation des modèles [Wang and LêCao \(2020\)](#).

2.5 Limites des approches classiques

Les méthodes classiques d'apprentissage automatique telles que Random Forest, SVM ou Lasso considèrent généralement chaque taxon comme une variable indépendante. Tou-

tefois, cette représentation ignore la structure hiérarchique naturelle de la taxonomie microbienne.

Cette absence d'information biologique peut limiter la sélection des variables pertinentes et réduire l'interprétabilité des modèles [Rojas-Velazquez et al. \(2024\)](#).

2.6 Méthodes informées par la taxonomie

Afin d'exploiter la structure biologique des données, des approches de type "**Taxonomy-Aware Feature Engineering**" intègrent l'organisation hiérarchique des taxons dans le processus de sélection de variables.

Ces méthodes utilisent les relations entre différents niveaux taxonomiques afin de construire des représentations plus informatives des profils microbiens.

Parmi ces approches, le **Hierarchical Feature Engineering** (HFE), proposé par *Oudah et Henschel en 2018*, exploite l'arbre taxonomique pour générer et sélectionner des variables représentant différents niveaux de classification.

Idée Clé : Utiliser l'Arbre Généalogique des Microbes

L'approche repose sur un principe simple : Les taxons appartenant à des groupes phylogénétiquement proches peuvent partager des propriétés fonctionnelles ou biologiques communes.

-> L'agrégation des abondances à différents niveaux taxonomiques permet de construire des représentations potentiellement plus robustes.

2.7 Problématique

Les méthodes classiques ignorent la structure taxonomique, tandis que HFE propose de l'exploiter via une représentation hiérarchique.

Néanmoins, les bénéfices réels de cette approche restent peu étudiés, notamment en termes de performances prédictives, de robustesse au bruit, de stabilité de sélection et de généralisation entre études. Ce travail vise donc à répondre aux questions suivantes :

- **HFE apporte-t-il réellement un gain par rapport aux approches classiques (Random Forest, SVM, Lasso ...) ?**
- **Les limitations de HFE peuvent-elles être corrigées par une approche statistique ?**
- **Les méthodes hiérarchiques de sélection de variables sont-elles robustes ?, stables ?**
- **Dans quelles conditions chaque méthode (HFE, SFE) est-elle pertinente ?**

2.8 Objectifs du stage

L'objectif principal de ce stage est d'évaluer l'apport des méthodes de sélection de variables informées par la taxonomie pour l'analyse de données microbiomiques.


Plus précisément, ce travail poursuit les objectifs suivants :

- **Réimplémenter et analyser l'approche HFE (*Hierarchical Feature Engineering*)** afin d'étudier son comportement sur différents jeux de données microbiomiques et d'identifier ses limites potentielles.

- **Développer une nouvelle approche de sélection de variables, SFE (*Statistical Feature Engineering*)**, exploitant l'information taxonomique tout en intégrant des critères statistiques de sélection et de contrôle des faux positifs.
- **Comparer HFE, SFE et les approches classiques** à travers différentes stratégies d'évaluation, en considérant à la fois les performances prédictives, la stabilité de sélection et la capacité de généralisation entre études.
- **Analyser les conditions dans lesquelles chaque méthode est pertinente**, notamment l'influence de la dimension des données, du nombre d'échantillons disponibles et de la robustesse face au bruit.
- **Comprendre les compromis** entre exploitation de **connaissances biologiques**, **stabilité des variables sélectionnées** et **capacité de généralisation des modèles**.

3 Méthodes Proposées

3.1 HFE (Hierarchical Feature Engineering)



La méthode HFE [Oudah and Henschel \(2018\)](#) exploite la structure hiérarchique de la taxonomie microbienne afin d'enrichir puis de réduire l'espace des variables selon quatre étapes principales :

1. **Agrégation hiérarchique** : Création de nouvelles variables correspondant aux nœuds internes de l'arbre taxonomique. L'abondance d'un nœud interne est obtenue par la somme des abondances de ses descendants directs :

$$o_{i_k}^j = \sum_{c \in C(i_k)} o_c^j$$

où $o_{i_k}^j$ représente l'abondance du nœud parent i_k dans l'échantillon j , et $C(i_k)$ l'ensemble de ses enfants.

2. **Filtrage par corrélation** : Les variables redondantes entre niveaux taxonomiques successifs sont supprimées. Un enfant S_l est éliminé lorsque sa **corrélation de Pearson** [Shaqiri et al. \(2023\)](#) avec son parent G_k dépasse un seuil fixé :

$$\rho(G_k, S_l) > \theta$$

indiquant que l'information portée par l'enfant est déjà représentée par son parent. (θ est un paramètre du model)

3. **Sélection par Gain d'Information** : Chaque nœud est évalué selon son information mutuelle avec le vecteur de localisation $\mathbf{y}$ [Greven et al. \(2014\)](#). Les variables dont le score est inférieur à la moyenne du chemin racine-feuille P sont supprimées :

$$IG(o_c, \mathbf{y}) < \frac{\sum_{p \in P} IG(o_p, \mathbf{y})}{|P|}$$

4. **Récupération des OTUs** : Les feuilles terminales (OTUs : les espèces de niveau le plus fin) présentant un score d'information mutuelle supérieur à la moyenne globale sont réintégrées dans l'espace final de variables sélectionnées.

3.2 Limites de HFE

Nos travaux identifient deux faiblesses critiques dans la conception de HFE :

- **Limitation de conception** : Le filtrage de redondance est principalement basé sur des relations verticales de la taxonomie (parent-enfant). Les dépendances entre taxons appartenant à des branches différentes de l'arbre ne sont pas explicitement prises en compte, [Lefèvre et al. \(2010\)](#).
- **Biais de l'estimation k-NN** : Le calcul du Gain d'Information par k plus proches voisins devient moins fiable sur des matrices très creuses, avec peu d'échantillons, conduisant à des prédictions erronées.

Ces limitations suggèrent qu'une stratégie reposant sur des tests statistiques, suivis d'un contrôle du taux de fausses découvertes et d'un filtrage de la redondance, pourrait constituer une alternative plus robuste. C'est dans cette optique que nous proposons l'algorithme "**Statistical Feature Engineering**" (SFE).

3.3 SFE (Statistical Feature Engineering)

Afin de remédier aux limites identifiées de HFE, nous proposons une nouvelle méthode de sélection de variables, nommée **Statistical Feature Engineering (SFE)**, conçue, développée et implémentée dans le cadre de ce stage.

SFE a également été conçue afin de tester l'hypothèse selon laquelle l'exploitation explicite de la hiérarchie taxonomique n'est pas systématiquement nécessaire : *une sélection reposant sur des critères statistiques rigoureux pourrait permettre d'obtenir des*

performances compétitives par rapport aux approches classiques ainsi qu'aux méthodes informées par la taxonomie.

Cette approche cherche ainsi à dépasser certaines limites identifiées de HFE, notamment sa dépendance aux relations hiérarchiques parent-enfant et aux difficultés d'estimation de la pertinence des variables. SFE repose sur un pipeline de filtrage statistique constitué des étapes suivantes (Figure 2) :




FIGURE 2 – Architecture globale de la méthode SFE (Statistical Feature Engineering).

- Génération de l'espace augmenté par agrégation taxonomique ;
- Évaluation de la séparation inter-classes par le test de Kruskal-Wallis ;
- Contrôle du taux de faux positives par correction Benjamini-Hochberg ;
- Élimination des redondances par filtrage de corrélation de Spearman.

- Agrégation multi-niveaux** sur l'ensemble des rangs taxonomiques.
- Test de Kruskal-Wallis** [Chicco et al. \(2025\)](#) (test non-paramétrique) évaluant la séparation des médians inter-classes sans hypothèse sur la distribution.
- Correction FDR de Benjamini-Hochberg** [Kwong et al. \(2002\)](#) au seuil α : paramètre du model, et par défaut $\alpha = 0.05$: $(fdr_p = P_k \cdot \frac{m}{k} \leq Q)$
- Filtrage par Corrélation de Spearman** [Shaqiri et al. \(2023\)](#) (Matrice de corrélation) afin de réduire les redondances entre variables fortement corrélées.

3.4 Implémentation (Pipeline scikit-learn)

Les méthodes HFE et SFE ont été implémentées sous forme de transformateurs personnalisés intégrés au framework `scikit-learn`, en héritant des classes de base `BaseEstimator` et `TransformerMixin`.

Cette architecture modulaire permet de chaîner directement le processus de sélection de variables avec les modèles de classification au sein d'un objet `Pipeline` unifié :

- La méthode `fit` calcule les statistiques requises (gain d'information pour HFE, p-valeurs du test de Kruskal-Wallis et seuils FDR pour SFE) sur la matrice d'entraînement.
- La méthode `transform` applique ensuite le filtrage et l'agrégation hiérarchique aux matrices d'abondance.

3.5 Protocole d'Évaluation : Validation Croisée Imbriquée

Afin de garantir une évaluation rigoureuse et exempte de fuite d'information (*Data Leakage*), l'ensemble du processus de sélection de variables et d'optimisation des modèles




FIGURE 3 – Schéma du protocole de Validation Croisée Imbriquée (*Nested Cross-Validation*). **a.** La **boucle externe** isole le jeu de test pour mesurer la généralisation. **b.** Pour chaque pli externe, le jeu d’entraînement est transmis à la **boucle interne** afin d’optimiser les hyperparamètres (seuils de corrélation, α FDR, paramètres du classifieur) sur des sous-ensembles de validation.

est encapsulé dans une **Validation Croisée Imbriquée** (*Nested Cross-Validation*) [Wainer and Cawley \(2021\)](#), illustrée par la Figure 3. Ce schéma se compose de deux niveaux d’évaluation distincts :

- **La boucle externe :** Elle isole strictement un jeu de test (*Test*) utilisé uniquement pour calculer la métrique finale (F_1 -score).
Deux protocoles complémentaires ont été utilisés :
 - validation croisée stratifiée imbriquée pour les expériences intra-étude 1 ;
 - validation Leave-One-Study-Out pour les expériences inter-études 2.
- **La boucle interne :** Elle est appliquée exclusivement au jeu d’entraînement externe (*Train*). Elle réalise une recherche sur grille (*GridSearchCV*) avec validation croisée pour sélectionner la combinaison optimale d’hyperparamètres (seuil de corrélation θ , niveau de significativité α pour le FDR, et hyperparamètres propres au classifieur (Random forest, SVM, Lasso)).

À chaque étape, les transformateurs *HFE* et *SFE* sont ajustés (*fit*) uniquement sur les blocs d’entraînement, puis appliqués (*transform*) sur les blocs de validation ou de test.


4 Évaluation Expérimentale

4.1 Test sanitaire sur les jeux de données CRC

Afin de valider le comportement du pipeline et d’écartier tout biais d’implémentation avant son déploiement sur les données de MicrobeAtlas, une évaluation préliminaire de référence (*sanity check*) a été conduite sur deux jeux de données de métagénomique fécale associés au cancer colorectal : **CRC1** [Zeller et al. \(2014\)](#) et **CRC2** [Feng et al. \(2015\)](#). Ces jeux opposent des échantillons de patients atteints de carcinome colorectal à des témoins sains. Le protocole expérimental reproduit strictement la méthodologie d’évaluation initiale de HFE décrite par [Oudah and Henschel \(2018\)](#).

Les performances prédictives ont été mesurées selon plusieurs métriques de classification (ROC-AUC, Précision, Rappel et F_1 -score). La Figure 4 présente : (a) Les performances obtenues sur la cohorte combinée CRC1+CRC2, ainsi que (b) la comparaison des courbes ROC-AUC évaluées individuellement sur CRC1 et CRC2.

Les résultats montrent que notre pipeline obtient des performances élevées sur les jeux de données CRC1 et CRC2, aussi bien sur la cohorte combinée que sur les études considérées séparément. Ces résultats indiquent que l'implémentation reproduit un comportement cohérent avec la littérature.



-> Les expériences suivantes peuvent ainsi être interprétées avec davantage de confiance, les performances observées étant peu susceptibles de provenir d'un défaut d'implémentation.

4.2 Performance : Validation intra-étude

Cette expérience vise à déterminer si l'exploitation de la hiérarchie taxonomique permet d'améliorer les performances prédictives au sein d'une même étude par rapport à une approche sans sélection de variables.

Le benchmark compare **Baseline** (modèle sans sélection des variables), **HFE** et **SFE** combinés à trois classifieurs (**Random Forest**, **Lasso**, **SVM**) sur les études ERP012803 ($N = 21545$), ERP120105 ($N = 9457$), SRP002395 ($N = 6265$) et SRP002860 ($N = 2794$), issues de MicrobeAltas dataset [Rodrigues et al. \(2026\)](#).

L'analyse des résultats de la Table 1 met en évidence plusieurs remarques :

- **Domination constante de SFE face à HFE** : Dans les configurations évaluées, SFE obtient de meilleures performances que HFE. Les gains observés atteignent jusqu'à +0.0429 points de F_1 score (sur l'étude ERP120105 avec Lasso), suggérant que la stratégie de sélection retenue par SFE est plus adaptée que celle employée par HFE dans ce contexte étudié.
- **Gains marqués sur les classifieurs linéaires et à noyau (Lasso et SVM)** : Lorsqu'elle est combinée avec Lasso ou SVM, SFE surpasse la Baseline sans sélection dans 100 % des cas (8/8 configurations). Par exemple, dans l'étude SRP002860, SFE permet d'augmenter le score F_1 de 0.8416 à 0.8755 pour Lasso et de 0.8337 à 0.8657 pour SVM, tout en réduisant la variance inter-plis dans plusieurs études.

TABLE 1 – **Performances d'intra-étude en validation croisée** (Test $F_1 \pm \text{std}$) sur 5 plis.

Étude	Classifieur	Baseline	HFE	SFE
ERP012803 ($N = 21545$)	Random Forest	0.7160 $\pm$ 0.029	0.6812 $\pm$ 0.019	0.6939 $\pm$ 0.034
	Lasso	0.6276 $\pm$ 0.035	0.6086 $\pm$ 0.016	0.6360 $\pm$ 0.032
	SVM	0.6686 $\pm$ 0.032	0.6432 $\pm$ 0.009	0.6798 $\pm$ 0.028
ERP120105 ($N = 9457$)	Random Forest	0.8817 $\pm$ 0.005	0.8402 $\pm$ 0.005	0.8817 $\pm$ 0.009
	Lasso	0.7964 $\pm$ 0.007	0.7682 $\pm$ 0.013	0.8111 $\pm$ 0.007
	SVM	0.8097 $\pm$ 0.007	0.7740 $\pm$ 0.012	0.8118 $\pm$ 0.006
SRP002395 ($N = 6265$)	Random Forest	0.9338 $\pm$ 0.015	0.9285 $\pm$ 0.009	0.9440 $\pm$ 0.014
	Lasso	0.9080 $\pm$ 0.012	0.9108 $\pm$ 0.017	0.9171 $\pm$ 0.012
	SVM	0.8950 $\pm$ 0.022	0.9033 $\pm$ 0.022	0.9042 $\pm$ 0.016
SRP002860 ($N = 2794$)	Random Forest	0.9226 $\pm$ 0.013	0.9006 $\pm$ 0.002	0.9222 $\pm$ 0.009
	Lasso	0.8416 $\pm$ 0.015	0.8574 $\pm$ 0.025	0.8755 $\pm$ 0.008
	SVM	0.8337 $\pm$ 0.011	0.8533 $\pm$ 0.017	0.8657 $\pm$ 0.008

- **Comportement face au Random Forest** : Random Forest sans sélection (Baseline) constitue une référence robuste, obtenant le meilleur score sur 3 des 4 études. Néanmoins, l'association **SFE + Random Forest** s'impose comme la meilleure performance sur l'étude **SRP002395** (0.9440 ± 0.014) et égalise parfaitement la Baseline sur **ERP120105** (0.8817).
- **Dégradation induite par HFE** : À l'exception de légères améliorations sur des modèles linéaires pour les deux études (**SRP002395** et **SRP002860**), la méthode HFE dégrade les performances par rapport à la Baseline sur 11 des 12 configurations.

La validation intra-étude mesure principalement la capacité du modèle à exploiter les signatures biologiques présentes dans une cohorte donnée. Elle ne garantit néanmoins pas la généralisation entre protocoles indépendants.

4.3 Validation inter-études (LOSO)

L'évaluation **Leave-One-Study-Out** (LOSO) évalue la capacité des modèles entraînés sur $(K - 1)$ études à prédire la localisation spatiale sur une autre étude indépendante jamais vue.

Les résultats obtenus (Figure 2) montrent qu'aucune des méthodes de sélection de variables n'est systématiquement supérieure en contexte d'inter-études. Les performances varient selon l'étude laissée de côté, traduisant une forte dépendance aux caractéristiques propres de chaque étude.

- La méthode **SFE** obtient les meilleures performances sur l'étude **ERP012803**, mais présente une dégradation importante sur les autres études. Cette observation peut s'expliquer par son caractère plus restrictif en termes de sélection de variables. En effet, les résultats de l'étude intra-étude 5 ont montré que SFE conserve systématiquement un nombre de variables inférieur à celui de HFE. Une telle réduction de

TABLE 2 – **Performances en inter-études (LOSO).** F_1 -score obtenu en test sur l'étude cible isolée.

Étude Test	Taille (N)	Baseline (RF)	HFE + RF	SFE + RF
ERP012803	21 545	0.4264	0.4021	0.4982
ERP015155	2 471	1.0000	0.3260	0.4986
ERP120105	9 457	0.3749	0.4758	0.1609
SRP002395	6 265	0.8133	0.6925	0.1435

dimension, bénéfique lorsque les distributions d'entraînement et de test sont proches, peut devenir pénalisante en présence d'un décalage entre études, certaines variables éliminées pouvant être discriminantes pour l'étude cible.

- À l'inverse, **HFE**, qui conserve un ensemble de variables plus important, obtient les meilleures performances sur l'étude **ERP120105** et surpasse SFE dans plusieurs cas, suggérant qu'une sélection moins agressive peut offrir une meilleure robustesse lorsque les distributions diffèrent entre les cohortes.
- Enfin, la méthode **Baseline (Random Forest)** obtient les meilleurs résultats sur deux des quatre études évaluées. En exploitant l'ensemble des variables disponibles, elle préserve toute l'information potentiellement discriminante, ce qui semble constituer un avantage dans un contexte de forte variabilité inter-études.

Ces résultats suggèrent que l'efficacité d'une stratégie de sélection de variables dépend fortement de l'étude cible et du degré d'hétérogénéité entre les cohortes. Dans ce contexte, aucune méthode de réduction de dimension ne s'impose systématiquement face à la baseline. Une sélection de variables trop agressive peut limiter la capacité de généralisation, tandis qu'une approche plus conservatrice, voire l'utilisation de l'ensemble des variables, peut s'avérer plus robuste selon les caractéristiques des données.

4.4 Analyse du comportement de HFE SFE

4.4.1 Évaluation de la Stabilité de Sélection et de la Robustesse au Bruit

En apprentissage automatique appliqué à la métagénomique, la sélection de caractéristiques (*feature selection*) ne doit pas seulement maximiser la performance prédictive, elle doit également garantir une **stabilité décisionnelle**. Ce défi est fréquemment identifié comme le problème de la reproductibilité des biomarqueurs [Jiang et al. \(2022\)](#).

Afin d'évaluer la stabilité et la robustesse des approches **HFE** et **SFE**, nous avons mis en place une expérience d'injection contrôlée de bruit log-normal sur deux études microbiomiques distinctes (ERP012803 et SRP002395).

Le bruit log-normal constitue une approximation contrôlée des variations multiplicatives pouvant affecter les abondances observées dans les données de séquençage haut débit, contrôlé par un paramètre d'intensité $\sigma \in \{0.05, 0.10, 0.20, 0.35, 0.50\}$.

Pour quantifier rigoureusement la stabilité du sous-ensemble de caractéristiques sélectionnées entre différentes réplifications ou partitions sous l'effet du bruit, nous utilisons l'**indice de Jaccard** [de Oliveira and Alves \(2017\)](#).

Soient S_i et S_j deux sous-ensembles de *features* sélectionnées issus de deux exécutions distinctes pour un niveau de bruit σ donné, le coefficient de Jaccard est défini formellement par :

$$J(S_i, S_j) = \frac{|S_i \cap S_j|}{|S_i \cup S_j|} \quad (1)$$

où $|S_i \cap S_j|$ désigne le nombre de caractéristiques communes sélectionnées et $|S_i \cup S_j|$ l'union totale des caractéristiques retenues. Un indice $J \rightarrow 1$ indique une stabilité absolue (sélections identiques), tandis qu'un indice $J \rightarrow 0$ traduit une forte divergence asymptotique de la sélection.

En complément de la stabilité, l'évaluation s'appuie sur deux autres métriques :

- **La performance du modèle** : mesurée par le F_1 -score du classifieur (Random Forest combiné aux algorithmes HFE ou SFE) afin d'évaluer son pouvoir prédictif.
- **La taille du signal biologique** : définie par le nombre moyen de *features* (taxons) sélectionnées par HFE ou SFE pour chaque niveau de bruit.




FIGURE 5 – Évaluation de la robustesse au bruit log-normal (σ) entre HFE et SFE. Évolution de la stabilité de sélection (indice de Jaccard, **a**, **d**), de la performance prédictive (F_1 -score, **b**, **e**) et du nombre de variables sélectionnées (**c**, **f**) pour les jeux de données ERP012803 (ligne du haut) et SRP002395 (ligne du bas). Les barres d'erreur indiquent l'écart-type ($\pm \text{std}$).

L'analyse comparative menée sur la Figure 5 permet de dégager trois conclusions principales :

1. **Dépendance de la stabilité vis-à-vis de l'étude ((a) et (d))** : L'indice de Jaccard entre chaque expérience et celle de base (expérience sans ajout de bruit) met en évidence une forte hétérogénéité selon la structure des données analysées. Sur l'étude ERP012803, les deux méthodes conservent une excellente stabilité décisionnelle : SFE conserve une stabilité maximale ($J = 1.0000$), tandis que HFE ne subit qu'une dégradation marginale ($J > 0.9890$ à $\sigma = 0.50$). À l'inverse, sur

l'étude SRP002395, le score de Jaccard de HFE diminue fortement dès que le bruit dépasse le seuil critique de $\sigma = 0.20$ (passant de 0.84 à ≈ 0.41). SFE subit également un fléchissement sur ce jeu de données ($J \approx 0.73$). Ce résultat démontre que **la stabilité de la sélection n'est pas une propriété intrinsèque absolue d'un algorithme, mais dépend aussi de l'étude considérée.**

2. **Robustesse prédictive ((b) et (e))** : Malgré les pertes de stabilité observées sur la deuxième étude, la performance de classification (F_1 -score) demeure remarquablement constante pour les deux approches sur l'ensemble de la plage de bruit injectée ($\sigma \in [0.05, 0.50]$). Cette invariance indique que les classifieurs parviennent à maintenir un pouvoir discriminant stable en compensant l'instabilité de sélection par l'utilisation de taxons ou de sous-ensembles de caractéristiques biologiquement et écologiquement équivalents.
3. **Conservation de la taille du signal biologique ((c) et (f))** : Le nombre de caractéristiques sélectionnées par HFE et SFE reste globalement stable pour les deux études malgré l'accroissement du bruit, avec de légères variations qui n'altèrent pas l'ordre de grandeur du sous-ensemble retenu par ces deux modèles.

4.4.2 Impact de la Haute Dimensionnalité (p/N)

En Microbiome, la taille des jeux de données varie considérablement d'une étude à l'autre, tant en nombre d'échantillons (N) qu'en nombre de taxons mesurés (p). Dans les régimes de haute dimensionnalité où le nombre de variables excède le nombre d'échantillons ($p/N > 1$), les algorithmes d'apprentissage automatique risquent de surapprendre et d'estimer de manière instable les statistiques de sélection.

Afin d'évaluer la sensibilité des méthodes au ratio p/N , nous avons conduit une expérience en faisant varier le nombre d'échantillons d'entraînement N par sous-échantillonnage contrôlé sur les études SRP002395 et SRP002860.

L'objectif est de déterminer si l'exploitation de la structure hiérarchique par HFE ou la sélection statistique par SFE apportent un gain robuste lorsque la quantité d'échantillons disponibles est très limitée.

Les courbes de la Figure 6 mettent en évidence trois régimes de comportement distincts

- **Régime de haute dimensionnalité ($p/N > 1.0$, $N < 200$)** : HFE subit une forte dégradation de ses performances, enregistrant les scores les plus bas ($F_1 = 0.537$ à $N = 65$ sur SRP002395 et $F_1 = 0.450$ à $N = 37$ sur SRP002860). À l'inverse, SFE conserve une grande stabilité dans ce régime ($F_1 = 0.757$ à $N = 65$ sur SRP002395) et s'égale avec la baseline sans sélection.
- **Régime de transition ($0.3 \leq p/N \leq 1.0$, $100 < N < 1000$)** : On observe la remontée la plus rapide pour HFE. À mesure que N augmente, la méthode rattrape son retard et rejoint les performances de SFE et de la baseline dans une plage comprise entre $F_1 \approx 0.83$ et 0.88 .
- **Régime de basse dimensionnalité ($p/N < 0.15$, $N > 2000$)** : La sélection de variables n'apporte plus de gain mesurable par rapport au modèle classique. Les trois courbes (HFE, SFE et Baseline) se superposent et convergent vers un plateau de performance identique ($F_1 \approx 0.90$ à 0.93).




FIGURE 6 – Évaluation de l’hypothèse de forte dimensionnalité (p/N). Évolution du F1-score en fonction du nombre d’échantillons (N , axe inférieur) et du ratio p/N (axe supérieur) en échelle log, pour les méthodes HFE, SFE et la baseline sans sélection.

4.4.3 Test de contrôle par sélection aléatoire des variables

Afin de vérifier que les performances obtenues avec SFE ne proviennent pas uniquement de la réduction du nombre de variables, un test de contrôle a été réalisé en comparant trois stratégies :

1. **Random Forest** : le modèle est entraîné directement sur l’ensemble des variables taxonomiques disponibles (baseline).
2. **SFE + Random Forest** : les variables sont sélectionnées par SFE puis utilisées pour entraîner un modèle Random Forest optimisé.
3. **Random Forest sur des variables aléatoires** : un nombre k de variables est sélectionné aléatoirement, où k correspond exactement **au nombre de variables retenues par SFE dans le même plis**. Cette sélection aléatoire est répétée 5 fois avec des graines (random_state) différentes afin d’évaluer la variabilité introduite par le choix des variables.


Pour chaque étude, l’évaluation suit une validation croisée stratifiée imbriquée (nested cross validation) [Wainer and Cawley \(2021\)](#).

L’expérience a été réalisée sur deux études présentant des comportements différents observés lors des analyses précédentes :

- **SRP002395** : étude dans laquelle SFE apporte une amélioration par rapport à la baseline (voir 1) ;
- **ERP012803** : étude où une dégradation des performances est observée après sélection (voir 1).

Les résultats du test de contrôle (Figure 7) montrent que **la performance de SFE ne provient pas uniquement de la réduction du nombre de variables**.

Pour les deux études, la sélection aléatoire d’un nombre équivalent de variables (k features) conduit à une diminution importante du F1 score en test, indiquant qu’un **sous-ensemble arbitraire de même dimension ne conserve pas l’information discriminante nécessaire à la classification**.



- Sur **ERP012803**, SFE maintient une performance comparable à l'utilisation de l'ensemble complet des variables ($F1 \sim 0.70$), tout en utilisant un nombre réduit de caractéristiques (~ 25 vs 2520 pour le baseline).
- sur **SRP002395**, SFE atteint une performance proche de la baseline complète ($F1 \sim 0.94$), avec un nombre de variables (~ 300 vs 2520 pour la baseline).

Ces résultats suggèrent que SFE conserve les variables informatives nécessaires à la classification, contrairement à une sélection aléatoire de variables de même taille.

5 Discussion

5.1 Comparaison HFE et SFE

Les résultats montrent que l'intégration de l'information taxonomique n'entraîne pas systématiquement une amélioration des performances prédictives. Bien que HFE exploite la structure hiérarchique des taxons, ses performances restent généralement inférieures à la baseline Random Forest dans les expériences intra-étude 1. Cette diminution suggère que l'ajout de représentations hiérarchiques peut parfois écarter des variables discriminantes, notamment lorsque le nombre d'échantillons est insuffisant.

À l'inverse, SFE présente des performances plus régulières, en particulier pour les modèles Lasso et SVM. La sélection statistique permet de conserver des variables informatives tout en limitant le bruit et les redondances.

Toutefois, les expériences "**inter-étude**" 2 montrent que l'avantage de SFE dépend du contexte, car les différences entre études peuvent également être influencées par des effets biologiques ou expérimentaux (Effet de batch [Wang and LêCao \(2020\)](#)).

HFE peut présenter une excellente stabilité dans certains jeux de données, mais cette propriété diminue dans des conditions plus difficiles. SFE offre une meilleure robustesse globale dans les régimes testés, notamment lorsque la dimension des données devient importante.

Ainsi, HFE et SFE répondent à deux stratégies différentes : HFE exploite explicitement la structure hiérarchique de la taxonomie, tandis que SFE privilégie une sélection statistique contrôlée. Dans les conditions expérimentales étudiées, SFE apparaît plus adaptée

aux données microbiomiques de haute dimension.

5.2 Impact de la structure taxonomique

L'utilisation de la taxonomie fournit une information biologique pertinente, mais son intégration doit être adaptée aux propriétés statistiques des données. HFE repose sur l'hypothèse que les taxons proches dans la hiérarchie partagent des informations communes. Cette hypothèse peut être bénéfique lorsque le nombre d'échantillons est suffisant, comme l'indique l'amélioration du comportement de HFE lorsque le ratio p/N diminue.

Cependant, l'agrégation hiérarchique peut également entraîner une perte d'information lorsque des taxons regroupés présentent des comportements écologiques différents. Dans les régimes de haute dimensionnalité ($p/N > 1$), l'estimation de la pertinence des variables hiérarchiques devient plus incertaine, ce qui limite l'efficacité de HFE.

SFE exploite également la structure taxonomique, mais applique ensuite des critères statistiques permettant de sélectionner uniquement les représentations présentant un signal discriminant. Ces résultats suggèrent que la taxonomie constitue une source d'information utile, mais qu'elle doit être combinée avec des mécanismes de sélection adaptés afin d'éviter l'introduction de variables peu pertinentes.

5.3 Limites expérimentales

Cette étude a vécu des limites principalement liées aux contraintes computationnelles et au temps disponible. Deux sources de données ont été préparées au cours du projet : MicrobeAtlas et Earth Microbiome Project (EMP). Toutefois, les expérimentations finales ont été réalisées uniquement sur MicrobeAtlas, le temps nécessaire à l'exécution complète des différents benchmarks n'ayant pas permis d'étendre l'analyse à EMP.

De plus, les évaluations ont été conduites sur un nombre limité d'études par rapport aux jeux initialement sélectionnés. Certaines analyses ont été réalisées sur deux à trois études, alors que sept études étaient disponibles. Cette réduction est principalement due au coût computationnel des méthodes étudiées. Les approches HFE et SFE nécessitent plusieurs étapes de transformation, d'agrégation et de sélection de variables, entraînant des temps d'exécution importants sur des jeux contenant plusieurs milliers d'échantillons. La taille élevée des matrices microbiomiques a également conduit à des contraintes de mémoire, limitant le nombre d'expériences pouvant être réalisées.

Une autre limite concerne la représentation des données microbiomiques. Les expériences ont principalement utilisé des abondances relatives, sans évaluer des transformations spécifiques aux données compositionnelles telles que la transformation CLR (*Centered Log-Ratio*) Bars-Cortina (2022). Ces approches pourraient permettre de mieux prendre en compte les contraintes propres aux données de séquençage.

Enfin, d'autres méthodes de sélection adaptées aux données microbiomiques, telles que CODA-Lasso ou Tree-Lasso Kamkar et al. (2015), n'ont pas pu être intégrées aux comparaisons par manque de temps. Leur évaluation permettrait de situer plus précisément les performances de HFE et SFE parmi les approches spécifiquement conçues pour les données compositionnelles et structurées.

5.4 Perspectives

Plusieurs perspectives peuvent être envisagées afin de prolonger et d'améliorer ce travail.

- Étendre les expérimentations au jeu de données *Earth Microbiome Project*, afin d'évaluer les méthodes sur un plus grand nombre d'études et de renforcer les analyses en validation inter-études (LOSO).
- Étudier l'impact de transformations adaptées aux données compositionnelles, telles que la transformation CLR (*Centered Log-Ratio*), en remplacement des abondances relatives.
- Comparer SFE et HFE à d'autres méthodes de sélection de variables dédiées aux données microbiomiques, notamment CODA-Lasso et Tree-Lasso.
- Mieux comprendre les différences de comportement entre HFE et SFE en analysant les variables sélectionnées, les niveaux taxonomiques retenus et l'influence des différentes étapes de sélection.

6 Conclusion

Ce stage avait pour objectif d'étudier l'apport de la structure taxonomique dans la sélection de variables pour la classification de données microbiomiques. Dans ce cadre, la méthode *Hierarchical Feature Engineering* (HFE) a été réimplémentée et évaluée, puis comparée à une nouvelle approche, *Statistical Feature Engineering* (SFE), développée au cours de ce stage.

Les expérimentations réalisées ont montré que l'utilisation de l'information taxonomique n'améliore pas systématiquement les performances prédictives. HFE exploite explicitement la hiérarchie taxonomique, et son efficacité dépend fortement des caractéristiques du jeu de données, notamment du rapport entre le nombre de variables et le nombre d'échantillons (p/N). À l'inverse, SFE a montré des performances plus régulières dans les conditions expérimentales étudiées, tout en conservant une bonne robustesse face au bruit et en améliorant les performances de plusieurs modèles de classification.

Au-delà de la comparaison entre HFE et SFE, ce travail met en évidence que l'exploitation de la taxonomie ne constitue pas, à elle seule, une garantie d'amélioration des performances. Les résultats soulignent l'importance de combiner les connaissances biologiques avec des méthodes statistiques adaptées afin de sélectionner des variables à la fois pertinentes, robustes et généralisables.

Enfin, ce stage a permis de développer un pipeline expérimental complet, depuis la préparation des jeux de données microbiomiques jusqu'à l'évaluation rigoureuse des méthodes par validation croisée imbriquée et validation inter-études. Les perspectives identifiées, notamment l'évaluation sur d'autres jeux de données, l'utilisation de méthodes adaptées aux données compositionnelles et l'étude approfondie des mécanismes expliquant les différences entre HFE et SFE, pourront être explorées dans de futurs travaux afin d'évaluer plus largement les approches proposées.

7 Bilan personnel

Ce stage m'a permis de découvrir le domaine du microbiome et, plus largement, la bioinformatique. Cette expérience m'a offert une nouvelle perspective sur l'application de l'apprentissage automatique aux sciences du vivant ainsi que sur le fonctionnement d'un laboratoire de recherche. Elle a renforcé mon intérêt pour ce domaine et m'a permis d'élargir ma vision des débouchés de l'informatique au-delà des applications classiques.

L'un des principaux défis a été l'appropriation d'un domaine scientifique qui m'était initialement peu familier. Comprendre les notions de taxonomie, les spécificités des données microbiomiques et la littérature associée a nécessité une phase importante d'apprentissage. Les échanges réguliers avec mes encadrants et la lecture d'articles scientifiques m'ont permis de surmonter progressivement ces difficultés.

Sur le plan technique, ce projet m'a confronté à la manipulation de jeux de données volumineux et à des contraintes importantes de temps de calcul et de mémoire. Ces difficultés m'ont amené à améliorer mes implémentations, à optimiser certaines étapes du pipeline expérimental et à adopter une démarche plus rigoureuse dans la conduite des expériences.

Enfin, ce stage m'a permis de développer des compétences en autonomie, en analyse critique des résultats et en communication scientifique. Il constitue une expérience enrichissante qui a renforcé mon intérêt pour la recherche et pour le développement de méthodes d'apprentissage automatique appliquées aux données biologiques.

Références

- Bars-Cortina, D. (2022). Alpha and beta-diversities performance comparison between different normalization methods and centered log-ratio transformation in a microbiome public dataset. *bioRxiv*, pages 2022–11.
- Berg, G., Rybakova, D., Fischer, D., Cernava, T., Vergès, M.-C. C., Charles, T., Chen, X., Cocolin, L., Eversole, K., Corral, G. H., et al. (2020). Microbiome definition re-visited : old concepts and new challenges. *Microbiome*, 8(1) :103.
- Chicco, D., Sichenze, A., and Jurman, G. (2025). A simple guide to the use of student’s t-test, mann-whitney u test, chi-squared test, and kruskal-wallis test in biostatistics. *BioData Mining*, 18(1) :56.
- de Oliveira, E. F. T. and Alves, B. H. (2017). Cosseno de salton, índice de jaccard e correlação de pearson : comparando índices normalizados e absolutos em análise de cocitação de autores. *Em Questão*, 23(5) :235–253.
- Feng, Q., Liang, S., Jia, H., Stadlmayr, A., Tang, L., Lan, Z., Zhang, D., Xia, H., Xu, X., Jie, Z., et al. (2015). Gut microbiome development along the colorectal adenoma–carcinoma sequence. *Nature communications*, 6(1) :6528.
- Greven, A., Keller, G., and Warnecke, G. (2014). *Entropy*. Princeton university press.
- Hillman, E. T., Lu, H., Yao, T., and Nakatsu, C. H. (2017). Microbial ecology along the gastrointestinal tract. *Microbes and environments*, 32(4) :300–313.
- Jiang, L., Haiminen, N., Carrieri, A.-P., Huang, S., Vázquez-Baeza, Y., Parida, L., Kim, H.-C., Swofford, A. D., Knight, R., and Natarajan, L. (2022). Utilizing stability criteria in choosing feature selection methods yields reproducible results in microbiome data. *Biometrics*, 78(3) :1155–1167.
- Kamkar, I., Gupta, S. K., Phung, D., and Venkatesh, S. (2015). Stable feature selection for clinical prediction : Exploiting icd tree structure using tree-lasso. *Journal of biomedical informatics*, 53 :277–290.
- Kwong, K. S., Holland, B., and Cheung, S. H. (2002). A modified benjamini–hochberg multiple comparisons procedure for controlling the false discovery rate. *Journal of Statistical Planning and Inference*, 104(2) :351–362.
- Lefèvre, T., Renaud, F., Selosse, M.-A., Thomas, F., Bernstein, C., Broennimann, O., Charlat, S., De Mazancourt, C., De Meeüs, T., Fleury, F., et al. (2010). Évolution des interactions entre espèces. *Biologie évolutive*, pages 533–616.
- McDonald, D., Clemente, J. C., Kuczynski, J., Rideout, J. R., Stombaugh, J., Wendel, D., Wilke, A., Huse, S., Hufnagle, J., Meyer, F., et al. (2012). The biological observation matrix (biom) format or : how i learned to stop worrying and love the ome-ome. *Gigascience*, 1(1) :7.
- Oudah, M. and Henschel, A. (2018). Taxonomy-aware feature engineering for microbiome classification. *BMC Bioinformatics*, 19(1) :227.

- Rodrigues, J. F. M., Tackmann, J., Malfertheiner, L., Patsch, D., Perez-Molphe-Montoya, E., Näpflin, N., Gaio, D., Rot, G., Danaila, M., Peluso, M. E., et al. (2026). The microbeatlas database : Global trends and insights into earth’s microbial ecosystems. *Cell*, 189(7) :2092–2107.
- Rojas-Velazquez, D., Kidwai, S., Kraneveld, A. D., Tonda, A., Oberski, D., Garssen, J., and Lopez-Rincon, A. (2024). Methodology for biomarker discovery with reproducibility in microbiome data using machine learning. *BMC Bioinformatics*, 25(1) :26.
- Shaqiri, M., ILJAZI, T., KAMBERI, L., and RAMANI-HALILI, R. (2023). Differences between the correlation coefficients pearson, kendall and spearman. *Journal of Natural Sciences and Mathematics of UT*, 8(15-16) :392–397.
- Silverman, J. D., Washburne, A. D., Mukherjee, S., and David, L. A. (2017). A phylogenetic transform enhances analysis of compositional microbiota data. *eLife*, 6 :e21887.
- Thompson, L. R., Sanders, J. G., McDonald, D., Amir, A., Ladau, J., Locey, K. J., Prill, R. J., Tripathi, A., Gibbons, S. M., Ackermann, G., and The Earth Microbiome Project Consortium (2017). A communal catalogue reveals earth’s multiscale microbial diversity. *Nature*, 551(7681) :457–463.
- Wainer, J. and Cawley, G. (2021). Nested cross-validation when selecting classifiers is overzealous for most practical applications. *Expert Systems with Applications*, 182 :115222.
- Wang, Y. and LêCao, K.-A. (2020). Managing batch effects in microbiome data. *Briefings in bioinformatics*, 21(6) :1954–1970.
- Zeller, G., Tap, J., Voigt, A. Y., Sunagawa, S., Kultima, J. R., Costea, P. I., Amiot, A., Böhm, J., Brunetti, F., Habermann, N., et al. (2014). Potential of fecal microbiota for early-stage detection of colorectal cancer. *Molecular systems biology*, 10(11) :MSB145645.

8 ANNEXE

TABLE 3 – Répartition du nombre d'échantillons par étude et par classe biologique pour le jeu de données MicrobeAtlas.

Study ID	Gut	Urogenital	Oral	Skin	Nose
ERP012803	18 904	37	1 339	1 265	–
ERP120105	1 670	850	1 844	4 260	833
SRP002462	–	8 926	–	–	–
SRP126946	–	–	7 259	–	–
SRP132490	–	7 186	–	–	–
SRP002395	445	365	3 872	1 214	369
SRP002860	153	110	1 652	649	230
ERP015155	2 471	–	–	–	–
SRP002480	–	2	–	2 407	–

TABLE 4 – Distribution du nombre d'échantillons par étude pour 8 études représentatives du dataset Earth Microbiome Project.

Study ID	Gut	Plant	Sediment	Soil	Surface	Water	Secretion
550	467	–	–	–	–	–	509
722	35	–	21	21	–	56	21
755	–	–	–	918	–	77	–
1024	–	139	–	98	–	–	–
1642	–	310	–	320	–	10	–
1747	49	18	–	4	24	3	53
1883	–	–	199	105	253	2 754	–
2192	–	–	–	–	690	–	315